2.2

该组数据均值是29.963，中位数是25。
该数据的众数是什么？**讨论数据的模态**（即二模、三模等）。
该数据的众数是25和35，是一个双峰的分布，即二模。
该数据的中列数是多少？
该数据的中列数是（70+13）/2=41.5。
你能粗略地找出该数据的第一个四分位数（Q1）和第三个四分位数（Q3）吗？
第一个四分位数为[27/4]=7处，Q1=20,；第三个四分位数为21处，Q3=35。
给出该数据的五数概括。
五数概括即中位数25，四分位数Q120，第三个四分位数Q335，最大观测值70和最小观测值13。

绘制该数据的盒图。

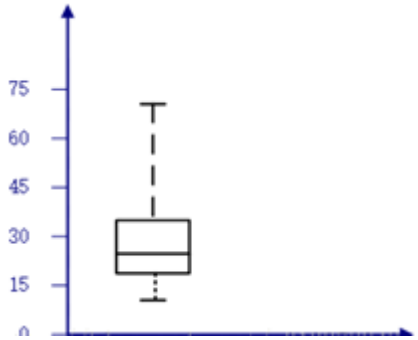

分位数-分位数图与分位数图有何不同？
分位数图是一种观察单变量数据分布的简单有效分发。首先它显示给定属性的所有数据的分布情况；其次它给出了分位数信息。
分位数-分位数图则是反映了同一个属性的不同样本的数据分布情况，使得用户可以很方便地比较这两个样本之间的区别或联系。

2.3

使用书中P47的计算公式，可以计算出
median=21+29*□((0.5-0.297)/0.470)=33.526
即近似中位数为33.526。

2.4

age的均值为46.44，中位数为（50+52）/2=51，标准差为12.85；
%fat的均值为28.78，中位数为（31.2+34.6）/2=32.9，标准差为8.99。

绘制age和%fat的盒图。

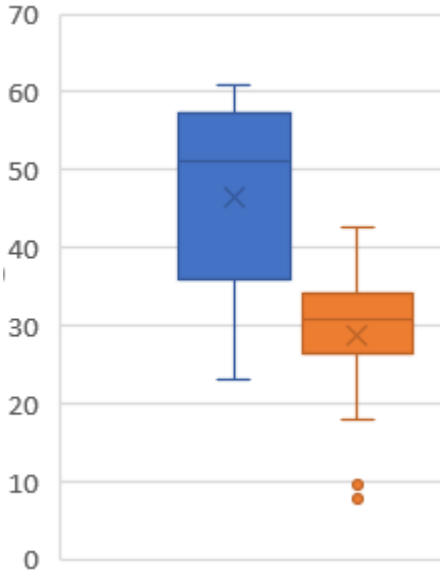

由于%fat中存在7.8和9.5两个数据被excel自动判定为离群点，故实际上%fat的图片中下须应该更长。

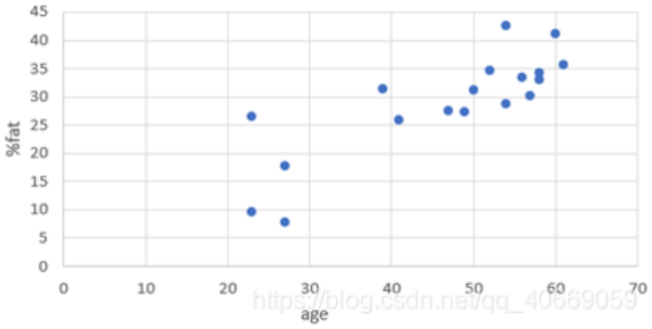

绘制基于这两个变量的散点图和q-q图。

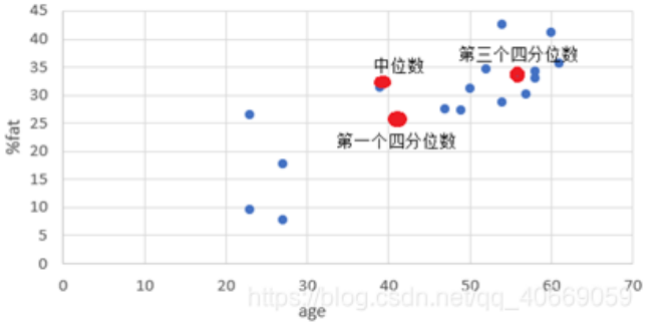

2.6

d=√(2&〖(22-20)〗2+〖(1-0)〗2+〖(42-36)〗2+〖(10-8)〗2)≈6.7
计算这两个对象之间的曼哈顿距离。
d=|22-20|+|1-0|+|42-36|+|10-8|=11
使用q=3，计算这两个对象之间的闵可夫斯基距离。
d=∛(〖(22-20)〗3+〖(1-0)〗3+〖(42-36)〗3+〖(10-8)〗3)≈6.15
计算这两个对象之间的上确界距离

答案

复制

（a）计算两个对象之间的欧几里得距离

$$d_{12}=\sqrt{(22-20)^2+(1-0)^2+(42-36)^2+(10-8)^2}=\sqrt{45}$$

（b）计算两个对象之间的曼哈顿距离

$$d_{12}=|22-20|+|1-0|+|42-36|+|10-8|=11$$

（c）计算两个对象之间的闵可夫斯基距离，其中参数r=3

$$d_{12}=\max(|p-q|)=6$$

3.3

讨论这种技术对给定数据的效果。

将以上数据分为三个一组的箱为：

（13,15,16）　（16,19,20）　（20,21,22）　（22,25,25）　（25,25,30）

（33,33,35）　（35,35,35,）　（36,40,45）　（46,52,70）

计算各个箱的平均值，给出以下结果。

（142/3，142/3, 142/3）　（181/3，181/3，181/3）　（21，21，21）

（24, 24, 24,）　（262/3，262/3，262/3）　（332/3, 332/3，332/3）

（35, 35, 35）　（401/3, 401/3, 401/3）　（56, 56, 56）

该方法在一定程度上光滑了噪声数据，但是在一定程度上还是会受到离群点的影响。

如何确定该数据中的离群点?

可以使用聚类检测，有相似特征的数据会聚集成一个簇，离簇较远的点可能是离群点。另外，还可以采用人机结合的方式，计算机将会给出疑似离群点，由人工进行复查确认是否需为离群点。

还有什么其他方法来光滑数据?

在分箱方法中，还可以通过箱中位数光滑、箱边界光滑等。或者使用回归技术和离群点分析技术。

3.6

令min=0，max=1，最小-最大规范化。

原始数据	200	300	400	600	1000
[0,1]规范化后	0	0.125	0.25	0.5	1

Z分数规范化。

$\bar{A}$=500，σ_A=282.8

原始数据	200	300	400	600	1000
Z 分数规范化	-1.06	-0.7	-0.35	0.35	1.78

Z分数规范化，使用均值绝对偏差而不是标准差。

$\bar{A}$=500，s_A=240

原始数据	200	300	400	600	1000
Z 分数规范化	-1.25	-0.83	-0.42	0.42	2.08

小数定标规范化。

令j=3，使用1000作为定标：

原始数据	200	300	400	600	1000
小数定标规范	0.2	0.3	0.4	0.6	1.0

修正后，应该取j=4，使用10000作为定标，则各数字应该为0.02,0.03,0.04,0.06，,01。

3.9

等频（等深）划分。

即划分为三个元素一样多的箱，即：

bin1	5，10，11，13
bin2	15，35，50，55
bin3	72，92，204，215

等宽划分。

分成三个区间即（215-5）/3=70，故区间距离为70，即：

bin1	5，10，11，13，15，35，50，55，72
bin2	92
bin3	204，215

聚类。

以数字间的最大间隔作为标准，即：

bin1	5，10，11，13，15
bin2	35，50，55，72，92
bin3	204，215

3.11

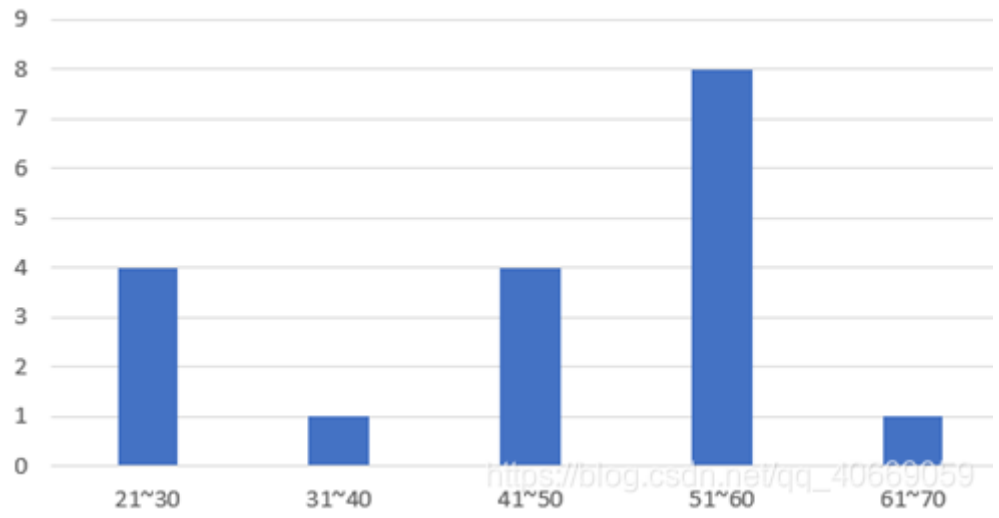

简要描述如下每种抽样技术的例子：SRSWOR、SRSWR、簇抽样、分层抽样。使用大小为5的样本以及层“young”、“middle_aged”和“senior”。

SRSWOR：即无放回简单随机抽取，从D中抽取s个样本，每次收取一个样本且不放回到D中。

ARAWR：有放回简单随机抽取，与SRSWOR的区别在于抽取出的样本会再放回到D中。

簇抽样：如果D中的元组被分组放到M个互不相交的簇中， 则可以得到s（s<M）个簇的简单随机抽样。

分层抽样：如果D被划分成互不相交的部分，则对每一层进行简单随机抽样就可以得到D的分层抽样。在本题中即对所说的三个层分别进行抽样，分配可以根据各层样本比例定为2、2、1个。

4.3

（a）流行用于数据仓库建模的三类模式是：星型模式、雪花模式和事实星座模式。

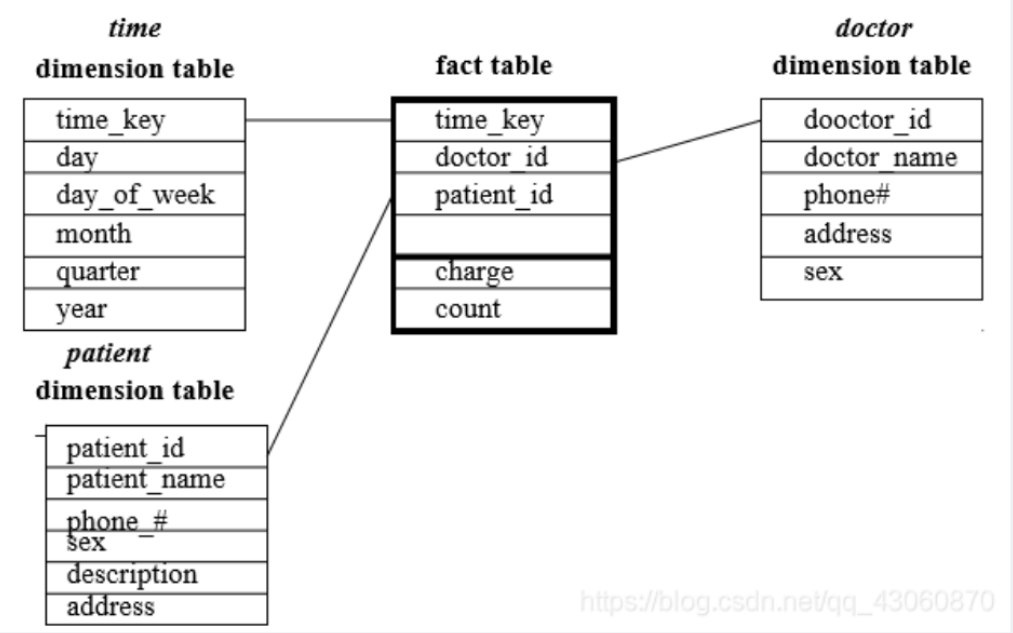

（b）

（c）time维：由“day”上卷到“year”， patient维：由“patient_name”上卷到“all”，对year=2010进行切片

（d）select doctor, SUM(charge) from fee where year=2010 group by doctor

4.4

（a）

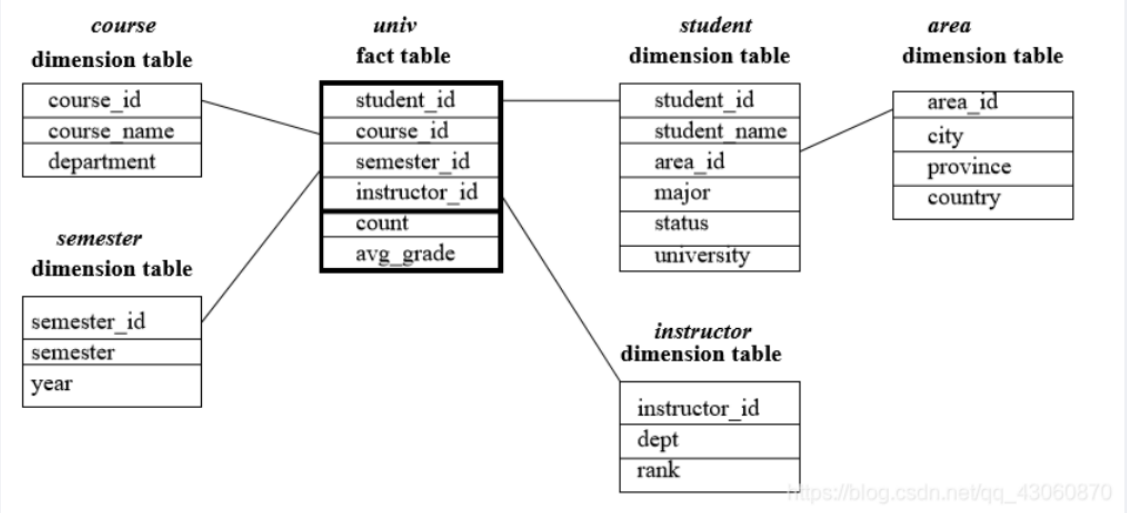

（b）• Roll-up on course from course_id to department.

• Roll-up on student from student_id to university.

• Dice on course, student with department=“CS” and university = “Big_University”.

• Drill-down on student from university to student name.

（c）这个数据立方体包含 $5^4 = 625$ 个方体。

4.5

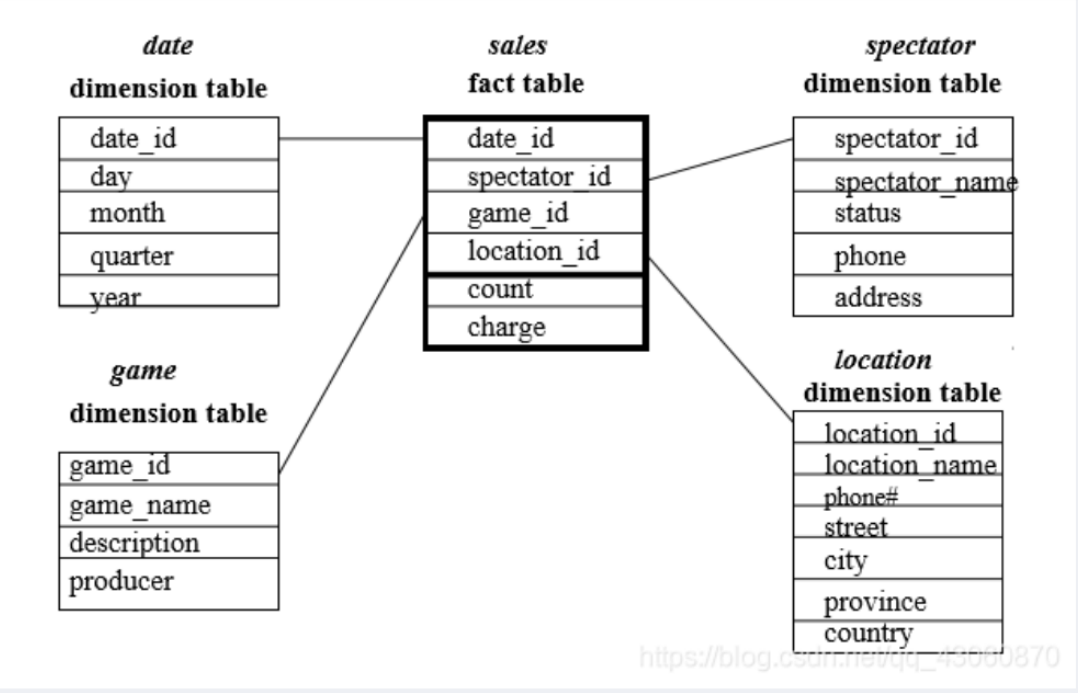

(a)

(b)• Roll-up on date from date_id to year.

• Roll-up on game from game_id to all.

• Roll-up on location from location_id to location name. • Roll-up on spectator from spectator_id to status.

• Dice with status="students", location_name="GM_Place", and year=2010.

(c)位图索引对于基数较小的值域是有利的。 例如，在此多维数据集中，如果对维度位置进行了位图索引，则位置上的比较，联接和聚集操作将化为位算术，从而大大减少了处理时间。 此外，长位置名称的字符串可以用一个位表示，这导致空间和I / O的显着减少。 对于具有高基数的维（例如本示例中的日期），用于表示位图索引的向量可能会很长。 例如，十年的数据收集可能会产生3650个日期记录，这意味着事实表中的每个元组都需要3650位（或大约456个字节）来保存位图索引。

第五章

习题一

- 数据库有4个事务。设min_sup=60%,min_conf=80%

TID	Itmes_bought
T100	{K,A,D,B}
T200	{D,A,C,E,B}
T300	{C,A,B,E}
T400	{B,A,D}

- 分别使用Apriori和FP-增长算法找出频繁项集。
- 列出所有的强关联规则（带支持度s和置信度c），它们与下面的元规则匹配，其中，X是代表顾客的变量，itmei是表示项的变量（例如：A、B等）

$$\forall x \in \text{transaction}, buys(X, itme_1) \wedge buys(X, itme_2) \Rightarrow buys(X, itme_3) \quad [s, c]$$

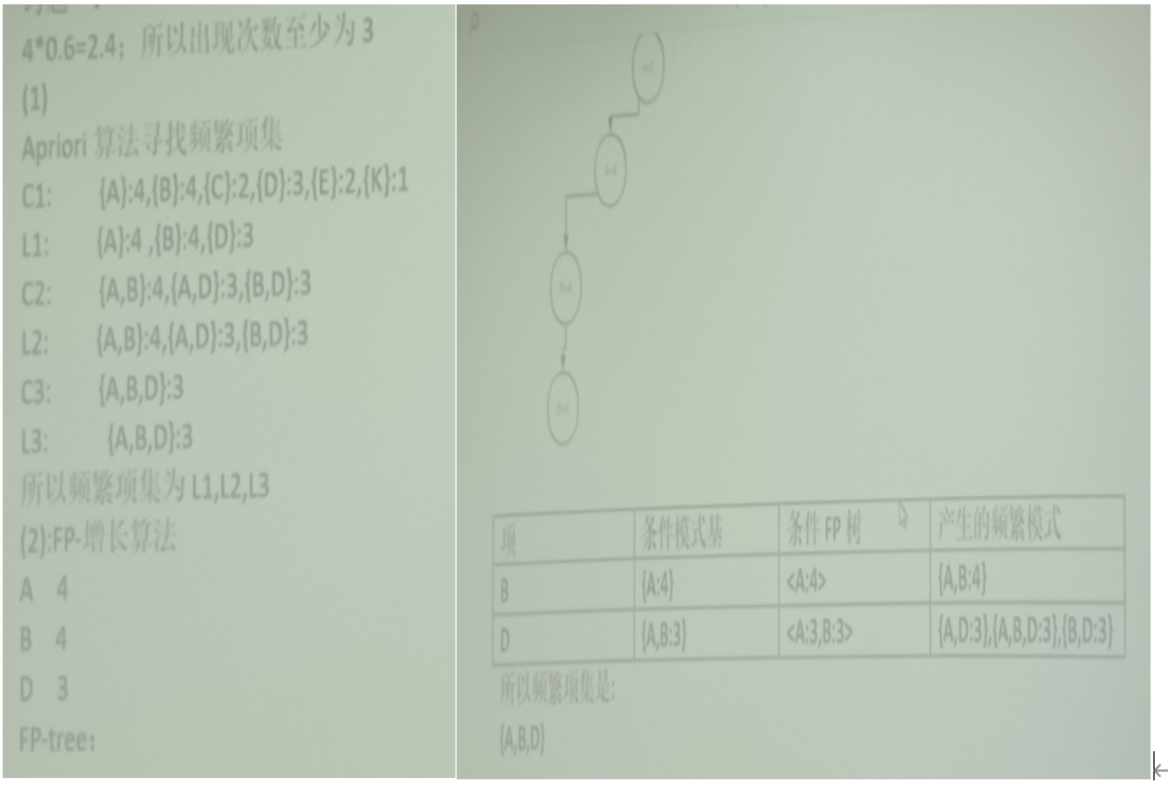

2

{A,B,D)子集:

- (A):4,(B}:4,{C}:3,{A,B}:4,(A,D}:3,{B,D}:3,(A,B,D):3关联规则:(A,B}=>D confidence=3/4=75%
- {A,D)=>B confidence-3/3=100%
- {B,D}=>A confidence=3/3=100%
- 因为 min_conf=80%;所以强关联规则为{B,D}=>A,(B,D}=>A,D=>{A,B)

习题二

- 下面的相依表总汇了超级市场的事务数据。其中，**hot dogs**表示包含热狗的事务，**non-hotdogs**表示不包含热狗的事务，**hamburgers**表示包含汉堡的事务，**non-hamburgers**表示不包含汉堡包的事务。

	hotdogs	Non-hotdogs	行汇总
hamburgers	2000	500	2500
Non-hamburgers	1000	1500	2500
列汇总	3000	2000	5000

- 假定发现关联规则”**hot dog => hamburgers**”。给定最小支持度阈值**25%**，最小置信度阈值**50%**，该关联规则是强的么？
- 根据给定的数据，买**hot dog**独立于买**hamburgers**么？如果不是，二者存在何种“相关”关系？

(1):Support(hot dog)=3000/5000=0.6

- Support(hamburgers)=2500/5000=0.5
- Support(hot dog U hamburgers)=2000/5000=0.4
- Confidence(hot dog=>hamburgers)=0.4/0.6>50%所以是强关联规则

（2）lift(hot dog,hamburgers)=0.4/(0.6*0.5)>1;说明两者正相关

习题三:

1:单调约束

2:反单调约束

3:单调约束

4:可转变约束

第八章

习题一

- 设status是类标号属性，给定一个数据元组，他在属性department,age和salary的值分别为“Systems”，“26…30”和“46K…50K”。该元组status的朴素贝叶斯分类是什么？

department	status	age	salary
Sales	Senior	31…35	46K…50K
Sales	Junior	26…30	26K…30K
Sales	Junior	31…35	31K…35K
Systems	Junior	21…25	46K…50K
Systems	Senior	31…35	66K…70K
Systems	Junior	26…30	46K…50K
Systems	Senior	41…45	66K…70K
Marketing	Senior	36…40	46K…50K
Marketing	Junior	31…35	41K…45K
Secretary	Senior	46…50	36K…40K
Secretary	Junior	26…30	26K…30K

习题一：
(1)
P(status=Senior)=5/11;
P(status=Junior)=6/11;
设属性 status=Senior 为 C1,status=Junior 为 C2
P(department=Systems|C1)=2/5;
P(department=Systems|C2)=1/3;

P(age=26…30|C1)=0;
P(age=26…30|C2)=1/2;

因为出现了 0 概率，所以要进行拉普拉斯校准:
C1 类里一共有 5 个样本，根据拉普拉斯校准，由于 age 一共有六个类，每个类增加一个样本，样本总数变为：5+6=11，所以，校准后的结果为：
P(age=26…30|C1)=1/11;

P(salary=46…50K|C1)=2/5;
P(salary=46…50K|C2)=1/3;
所以

所以
P(X|C1)=2/5*1/11*2/5=0.0145;
P(X|C2)=1/3*1/2*1/3=1/18=0.056;
所以属于 Junior0

习题二

- ◆右表给出学生的期中和期末考试成绩。
  - ◆绘数据图。X和Y看上去具有线性关系么?
  - ◆使用最小二乘法，求由学生的期中成绩预测学生的期末成绩的方程式。
  - ◆预测其中成绩为86分的学生的期末成绩。

X（期中考试）	Y（期末考试）
72	84
50	63
81	77
74	78
94	90
86	75
59	49
83	79
65	77
33	52
88	74
81	90

(1):绘制数据图

直观看上去有线性关系

(2):

设 Y = α + β X ;

$$\beta = \frac{\sum_{i=1}^{s}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{s}(x_i - \bar{x})^2} \qquad \alpha = \bar{y} - \beta\bar{x}$$

X 平均值=72.17，Y 平均值=74；

代入计算可得 y=0.58X+32.14

(3):

将 x=86 代入计算得到 y=82.02